黄凯佳 Kaijia Huang

+86 13288087830 h185694434
atyou813@163.com atyou88.github.io



教育背景

南京大学 计算机技术 硕士研究生 2025 年至今
导师：程龚教授（Websoft 研究组）；推荐免试入学。
研究方向：信息检索、大语言模型智能体、检索增强生成（RAG）、知识图谱。

厦门大学 计算机科学与技术 本科 2021–2025 年
本科生国家奖学金 **综合排名：2/127** GPA：3.68/4.00 加权平均分：87.82/100

科研经历

From Intent to Improvement: Agentic Dataset Search for Better Model Training
WWW 2027 在投 **共同第一作者**

- 提出基于类型化契约的 AgenticDS 数据集检索框架，分离需求规划、确定性执行与独立评审，融合混合检索、受限图谱扩展和局部搜索修正。
- 为候选数据集保留文本、元数据、内容样例与图谱关系的来源，逐项核验其是否符合训练需求。消融表明，缺少核验时，图谱扩展会降低排序质量。
- 构建 HuDS-Bench，覆盖 200 条自然语言需求和 24,908 个分级标注。在 15 种检索系统的对比中，NDCG@10 较最强稠密–稀疏混合基线和最强智能体基线分别提升 25.7% 和 18.9%。
- 建立从检索到训练的评测流程，以检索结果对三个基座模型进行监督微调，在数学、代码和医学的八项评测中，三领域平均分较次优数据获取方法高 3.06 分。

Benchmarking Recommendation, Classification, and Tracing Based on Hugging Face Knowledge Graph
SIGIR 2025 **第二作者**

- 构建面向 Hugging Face 开源机器学习资源的知识图谱 HuggingKG，包含 260 万个节点、620 万条边，整合模型、数据集、用户与任务，刻画模型演化、用户交互及丰富文本属性。
- 构建多任务基准 HuggingBench，覆盖模型与数据集之间的跨类型推荐、资源的多标签任务分类，以及基于微调、量化等衍生关系的模型谱系溯源。
- 基线实验发现，资源相关子图对推荐的帮助因方法而异，描述文本的嵌入能改善任务分类；模型溯源的答案通常接近唯一，经典方法 TransE 取得最高的 MRR（0.5589）。

实习经历

南京大学数据科学联合研究院 2026.07~2026.11
大模型应用研发

- **长文档解析**：开发结构化处理流程，衔接页级 OCR、问答拆分和事件要素抽取；结合模型判断与规则校验归并跨文档事件，保留原文位置供复核。
- **跨文档关联**：开发事件与文档关联模块，结合向量相似度与词项匹配检索候选材料，核验关联依据及原文位置；支持按需比对跨文档叙述并保留人工复核结果。
- **大模型结构化输出**：对模型返回的 JSON 进行字段校验，保留有效结果，按需缩小生成范围并修复缺失或格式不符的条目。

竞赛情况

- ICPC 国际大学生程序设计竞赛亚洲区域赛（西安站）**金牌** 2022 年
- CCPC 中国大学生程序设计竞赛（哈尔滨站）**银奖** 2023 年
- ICPC 国际大学生程序设计竞赛亚洲区域赛（南京站）**银牌** 2022 年